Mini-projeto: atenção em séries temporais

Previsão multivariada do clima de Jena com um codificador Transformer

27 de outubro de 2026

Resumo

Um codificador Transformer é aplicado à previsão multivariada do conjunto Jena Climate (2009–2016) para prever o próximo token e as 24 h seguintes. Em comparação com um *baseline* que repete o último valor observado, o MSE padronizado no teste (média de 3 sementes) cai de 0,0606 para 0,0479 no próximo token e de 0,6230 para 0,2825 em 24 h. Os mapas de atenção mostram foco no estado recente para o próximo token e cabeças especializadas em diferentes escalas de tempo para 24 h. Código: `https://github.com/evaniellycorreia/Mini-Projeto-Transformers`.

1 Dados e análise estatística

O conjunto tem 420 551 registros de 14 variáveis meteorológicas, a cada 10 min, de 01/01/2009 a 01/01/2017. As colunas `wv` e `max. wv` têm 18 e 20 valores iguais a -9999 (erros de sensor), preenchidos por interpolação linear para preservar a grade regular. A velocidade média `wv` foi ainda limitada pela rajada `max. wv` do mesmo intervalo, o que elimina um valor espúrio de 28,49 m/s. As escalas são muito distintas (`p`: $989{,}2 \pm 8{,}4$ mbar; `T`: $9{,}5 \pm 8{,}4\,^{\circ}$C, de -23 a $37\,^{\circ}$C; `rho`: 1216 ± 40 g/m^3; `wv`: $2{,}1 \pm 1{,}5$ m/s), o que justifica a padronização. Há forte correlação entre `Tdew`, `VPact`, `sh` e `H2OC`, e caudas longas em `max. wv` (até 23,5 m/s) e `VPdef`.

Divisão e janelas. A divisão é cronológica: 80% para treino (até 24/05/2015) e 20% para teste. O `StandardScaler` foi ajustado só no treino, para evitar vazamento. As janelas têm entrada de $L = 144$ passos (24 h) e alvo de 1 passo (próximo token) ou de 144 passos (24 h). Cada token agrupa s passos de 10 min, de modo que $m = L/s$ e a dimensão de cada token é $14s$.

2 Representação densa

A janela $X \in R^{m \times 14s}$ passa por: (i) **projeção linear** de cada token para dimensão n; (ii) **codificação posicional senoidal**, somada ao token, pois a atenção sozinha ignora a ordem; (iii) N **blocos codificadores**, cada um com *autoatenção multi-cabeça* (h cabeças, pesos $\mathrm{softmax}(QK^{\top}/\sqrt{d_k})$, em que cada token consulta todos os outros), *conexões residuais com normalização de camada*, que estabilizam o treino, e uma *rede feed-forward* por posição (duas camadas lineares com ReLU, largura $4n$); e (iv) uma **camada linear de saída**, que mapeia o vetor do último token para os $H \times 14$ valores previstos ($H = 1$ ou 144).

Função de perda. Usou-se o MSE sobre os dados padronizados,

$$\mathcal{L} = \frac{1}{B\,H\,14} \sum_{b,h,j} \left(\hat{y}_{b,h,j} - y_{b,h,j}\right)^2 . \tag{1}$$

A tarefa é de regressão contínua; o MSE é diferenciável, penaliza mais os erros grandes e, com a padronização, pondera as variáveis de forma comparável. Como desvantagem, em horizontes longos leva à média condicional e suaviza extremos.

Configuração. Adam (10^{-3}), *batch* de 64, 5 épocas e norma do gradiente limitada a 1,0. Por limitação de CPU, o treino usa 1 a cada 24 janelas ($\approx$14 000) e o teste, 1 a cada 12. Configuração principal: $s = 1$ ($m = 144$), $n = 64$, $h = 4$ e $N = 2$. Os resultados são médias das sementes 1, 2 e 3, e as figuras são da semente 1.

3 Resultados

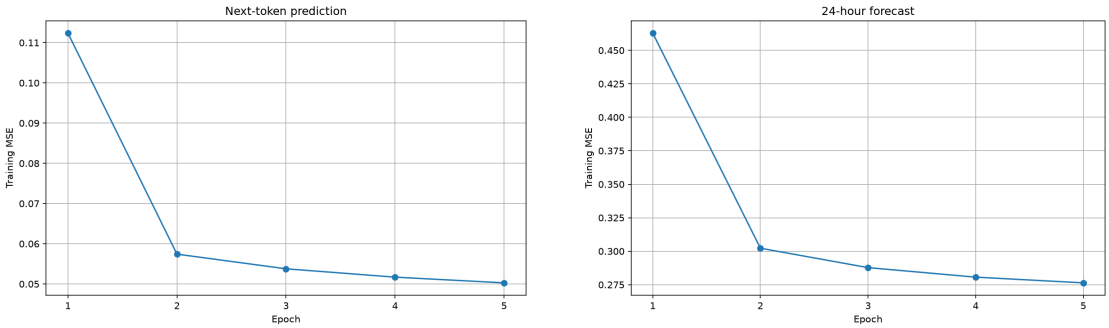


Figura 1: MSE de treino por época. Esquerda: próximo token. Direita: 24 h.

A perda cai fortemente até a segunda época e depois entra em platô, ainda decrescente na quinta (Fig. 1). O Transformer reduz o erro em cerca de 21% no próximo token e 55% em 24 h (Tab. 1). A variação entre sementes é menor que 1% da média, muito inferior à diferença para o *baseline*. O ganho é menor a 10 min, porque repetir o último valor já é um bom preditor nesse horizonte.

Tabela 1: MSE padronizado no teste (média ± desvio-padrão, 3 sementes).

Objetivo	Transformer	*Baseline* (último valor)
Próximo token	$0{,}0479 \pm 0{,}0003$	0,0606
24 h (144 passos)	$0{,}2825 \pm 0{,}0019$	0,6230

Tabela 2: MSE por variável no teste (24 h): modelo (média de 3 sementes, desvio $\leq 0{,}011$) / *baseline*.

Variável	Mod./Base	Variável	Mod./Base	Variável	Mod./Base
p	0,146 / 0,184	VPmax	0,166 / 0,603	rho	0,099 / 0,263
T	0,091 / 0,285	VPact	0,121 / 0,156	wv	0,716 / 1,345
Tpot	0,095 / 0,291	VPdef	0,394 / 1,435	max. wv	0,670 / 1,346
Tdew	0,088 / 0,110	sh	0,122 / 0,159	wd	0,746 / 1,270
rh	0,380 / 1,117	H2OC	0,122 / 0,158		

Os maiores ganhos ocorrem nas variáveis com ciclo diário marcado (`T`, `Tpot`, `rh`, `VPmax`, `VPdef`, `rho`), em que o erro cai para cerca de um terço do *baseline*. As variáveis lentas (`p`, `Tdew`, `VPact`, `sh`, `H2OC`) ganham de 20 a 25%. O vento tem o pior erro absoluto (0,67 a 0,75), por ser ruidoso e pouco previsível a 24 h.

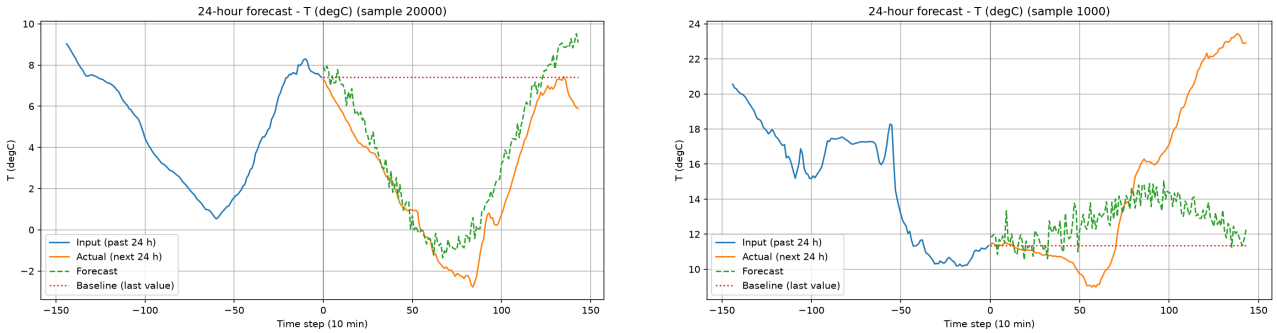


Figura 2: Previsão de 24 h para `T`. Esquerda: janela 20000 (ciclo regular). Direita: janela 1000 (mudança brusca). A linha pontilhada é o *baseline*.

Na janela regular (Fig. 2), o modelo acompanha a queda noturna até $\approx -1\,^{\circ}\mathrm{C}$ e o aquecimento seguinte. Na janela com mudança brusca, prevê uma variação suave entre 11 e 15 °C e não antecipa a queda a 9 °C nem a subida a 23 °C. Em suma, o modelo acerta a fase do ciclo diário, mas subestima a amplitude e não prevê

eventos sinóticos ausentes da entrada, como se espera de uma perda MSE. O ruído de alta frequência vem de a camada de saída estimar cada passo de forma independente.

Hiperparâmetros. A Tab. 3 varia s (e, portanto, m), n, h e N no objetivo de 24 h (3 épocas, metade das janelas de treino, semente 1). Todas as configurações ficam entre 0,31 e 0,36, bem abaixo do *baseline* (0,623). Só $n = 32$ piora claramente, o que sugere capacidade insuficiente. As demais diferenças (0,312 a 0,320) estão na ordem da variação entre execuções. Agrupar passos ($s = 6$ ou 12) quase não altera o erro e reduz o custo computacional.

Tabela 3: Varredura de hiperparâmetros (MSE de teste, 24 h). Referência: $s = 6$, $n = 64$, $h = 4$, $N = 2$; cada coluna altera um único parâmetro.

Config.	s=1	ref.	s=12	n=32	n=128	h=2	h=8	N=1	N=4
m	144	24	12	24	24	24	24	24	24
MSE	0,314	0,315	0,319	0,357	0,312	0,316	0,313	0,315	0,320

4 Mapas de atenção

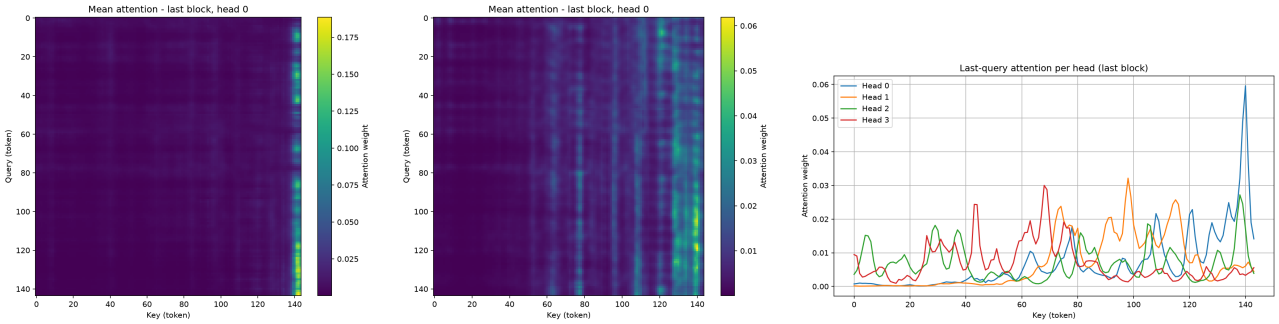


Figura 3: Esquerda e centro: atenção média da cabeça 0 do último bloco (8 janelas de teste) para o próximo token e para 24 h. Direita: atenção da última query por cabeça, em 24 h (32 janelas). A atenção uniforme vale $1/144 \approx 0{,}007$.

Próximo token. Quase toda a atenção recai sobre as últimas quatro chaves (140 a 143), com pico de $\approx 0{,}18$, cerca de 25 vezes a atenção uniforme. Para prever 10 min à frente, o modelo usa essencialmente o estado mais recente, o que é coerente com a força do *baseline* nesse horizonte.

24 h. A atenção se espalha pela segunda metade da janela, em faixas verticais (posições ≈63, 78, 96, 108, 121, 128 e 140) que se repetem para quase todas as queries. O peso é maior perto do fim, mas o modelo consulta instantes de até ≈13 h antes.

Especialização das cabeças. Como a previsão usa apenas o último token, a linha da última query (Fig. 3, direita) mostra o que o modelo de fato consulta. A cabeça 0 se concentra nas últimas ≈6 h (pico em 140); a cabeça 1, de 4 a 12 h antes (pico em 98); a cabeça 3, de 11 a 20 h antes (picos em 44 e 68); e a cabeça 2 distribui picos por toda a janela. A atenção multi-cabeça decompõe o histórico em escalas recentes e remotas, o que ajuda a projetar o ciclo diário. *Ressalvas:* poucas amostras, um único bloco e uma única semente. Peso de atenção não implica relevância causal, e uma janela de 24 h não permite verificar periodicidade diária diretamente.

5 Comentários finais

Um codificador Transformer simples supera de forma consistente o *baseline* nos dois objetivos, com ganho maior em 24 h e nas variáveis com ciclo diário. Limitações: treino curto e subamostrado, perda MSE que suaviza extremos e ausência de variáveis de calendário. Melhorias possíveis: mais épocas, codificação de hora do dia e estação, um decodificador autorregressivo e perda de Huber para o vento. Reprodução: `python 01_analise_dados.py -seeds 1 2 3` (<`https://github.com/evaniellycorreia/Mini-Projeto-Transformers`>).